Sincronização de *threads* movimentando em uma grade Exercício Prático - Fundamentos de Sistemas Paralelos e Distribuídos

Vinicius Silva Gomes {2021421869}¹

Departamento de Ciência da Computação Universidade Federal de Minas Gerais (UFMG) – Belo Horizonte, MG – Brasil

{vinicius.gomes}@dcc.ufmg.br

1. Introdução

A programação em múltiplas *threads* surgiu da necessidade de melhorar o desempenho e a eficiência de sistemas computacionais, especialmente em ambientes com múltiplos processadores. A ideia por trás é que várias tarefas sejam executadas simultaneamente em diferentes fluxos de execução, em um mesmo computador.

Isso trouxe inúmeros benefícios do ponto de vista de desempenho, concorrência/paralelismo e responsividade de sistemas, no entanto, também trouxe diversos desafios junto. O compartilhamento de recursos pode levar a condições de corrida e *deadlocks*, o acesso a recursos compartilhados deve ser muito bem gerenciado para que não hajam problemas de consistência entre os acessos, etc. Portanto, o desenvolvimento nesse modelo vem acompanhado de preocupações que não existem no modelo *single-thread*.

Nesse sentido, a proposta desse exercício prático é implementar um sistema de sincronização entre *threads* que se assemelha a um sistema de controle de movimentação para um jogo digital ou para o controle de robôs. A ideia é que através desse sistema, todas as vantagens e desafios por trás do desenvolvimento *multithreading* sejam explorados, principalmente quanto a sincronização de acesso a estruturas compartilhadas.

2. Estruturas, variáveis e funções

Para o desenvolvimento do programa, três *structs* principais foram utilizados: position_t, thread_t e cell_t. Além disso, as variáveis globais lock, condition, occupied e as funções move, enter, leave e passa_tempo são responsáveis por manipular os dados da entrada e realizar o movimento das *threads* ao longo do *grid*.

2.1. Estruturas

2.1.1. position_t

Um *struct* simples que contém três inteiros: x, y e wait_time. É uma estrutura instanciada dentro do *struct* da *thread* que armazena as coordenadas de uma posição (x, y) pela qual a *thread* deve passar e o tempo que essa *thread* deve ficar nessa posição.

2.1.2. thread_t

É o *struct* que armazena as informações de cada *thread* que são lidas da entrada. Ele armazena o *id* e o grupo da *thread*, o número de posições que serão percorridas por ela e

um vetor de tipo estruturado position_t, que define as posições presentes no caminho que ela irá percorrer no *grid*.

Uma variável com esse tipo é instanciada antes de cada *thread* ser criada e é passada como parâmetro para a função que determina o comportamento de cada *thread* que é executada.

2.1.3. cell t

Um *struct* auxiliar que armazena um inteiro (que funciona como *booleano*) para indicar se a vaga na posição está disponível ou não e os inteiros referentes ao *id* e ao grupo de uma *thread*, caso exista alguma *thread* ocupando aquela vaga. Ele é usado como tipo estruturado para o tensor occupied (que será melhor destrinchado na próxima subseção).

Sua finalidade é facilitar a identificação da *thread* que ocupa uma das vagas de uma posição do *grid*, caso essa exista, armazenando as informações que são pertinentes para os métodos de entrada e saída de *threads* em posições do *grid*.

2.2. Variáveis

Todas as variáveis listadas aqui são variáveis globais e, portanto, são acessíveis em todos os pontos do programa. As variáveis locais usadas pelas funções foram omitidas.

2.2.1. lock e condition

São matrizes de tipo pthread_mutex_t e pthread_cond_t, respectivamente. A primeira armazena os *mutexes* e a segunda as variáveis de condição associadas a cada posição no *grid*. Essas duas estruturas em conjunto permitirão o acesso à seção crítica de maneira controlada e que as *threads* possam entrar em espera e ser acordadas de acordo com o status da posição que desejam acessar.

Em especial, as travas e o sinal wait possibilitarão que as *threads* aguardem até que possam acessar uma nova posição do *grid* sem violar as restrições estabelecidas. Além disso, o sinal signal irá permitir que uma *thread*, ao deixar uma posição, acorde as outras *threads* que estão esperando pelo acesso a essa posição que ela deixou. Isso irá possibilitar que o programa, de modo geral, execute sem que um estado onde não é possível realizar progresso seja atingido.

Essas estruturas foram modeladas como matrizes porque a definição do problema beneficiava essa modelagem. Como nenhum tipo de varredura é feito na estrutura com a posição atual de cada *thread* no *grid*, apenas acessos pontuais à posições são feitos, modelar os *mutexes* a nível de posição possibilita que *threads* que querem acessar posições diferentes executem de forma independente, sem a necessidade de travar a estrutura como um todo e impedir que todas as outras *threads* progridam.

O mesmo vale para as variáveis de condição. A modelagem delas a nível de posição permite que somente as *threads* que se interessam por uma posição entrem em espera ou sejam acordadas. Assim, *threads* que não estão em um trecho do caminho onde há disputa pelo acesso a uma posição não são impactadas e progridem de forma independente.

Modelagens diferentes poderiam fazer com que conjuntos maiores de *threads* entrassem em espera sem necessidade ou fossem acordadas sem que houvesse alguma mudança no status das *threads* que estão executando na posição que as interessa. Esses cenários prejudicariam a execução do programa, que não aconteceria da melhor forma possível.

2.2.2. occupied

É um tensor de tipo cell_t. Ele é responsável pelo controle interno do programa com relação à posição de cada *thread* durante a execução. Sempre que uma *thread* entrar em uma nova posição ou deixar a posição atual, occupied será atualizado para refletir essas mudanças. Assim, esse tensor é a região de memória compartilhada pelas *threads* e, portanto, seu acesso e manipulação representam seções críticas que devem ser protegidas pelos *mutexes*, para que não hajam inconsistências.

As primeiras duas dimensões do tensor indexam uma posição no grid e terceira dimensão armazena duas posições ou vagas. A modelagem é essa pois no máximo duas threads podem estar na mesma posição, em um dado momento, caso ambas façam parte de grupos diferentes. Assim, cada thread pode preencher uma das duas vagas com seu id e grupo, indicando que ela está ocupando aquela vaga na posição (x, y).

2.3. Funções

2.3.1. enter

Função chamada pela *thread* quando deseja acessar uma posição (x,y) do *grid*. Ela recebe como parâmetro os inteiros referentes a posição e o *id* e grupo da *thread*. Inicialmente, a função trava o acesso a posição (x,y) usando o *mutex* associado a essa posição e verifica as condições para que a *thread* possa entrar na posição:

- As duas vagas não estão ocupadas;
- Não existe nenhuma outra *thread* do mesmo grupo da *thread* atual ocupando alguma das vagas da posição.

Caso alguma das condições não seja satisfeita, a *thread* entra em espera no corpo do *loop*, através do sinal wait associado à variável de condição e ao *mutex* da posição (x,y) que é disparado. Essa *thread* sairá dessa espera quando alguma outra *thread* enviar um signal associado a mesma posição.

Quando a *thread* sai do *loop*, temos que ambas as vagas estão vazias ou apenas uma delas está ocupada por uma *thread* com grupo diferente da *thread* atual. Sendo assim, a função encontra a vaga disponível, marca ela como ocupada e a preenche com o id e o grupo da *thread* atual. Por fim, a função libera o *lock* da posição (x, y) e termina.

2.3.2. leave

Função executada quando uma *thread* deseja liberar o acesso de uma posição que estava anteriormente. Ela recebe como parâmetros as coordenadas da posição e o *id* da *thread* que está saindo.

Inicialmente, a função trava o acesso a posição (x,y) informada e verifica em qual das duas vagas dessa posição os dados da *thread* estão. Quando a posição é encontrada, id e grupo são definidos como -1 e a vaga é marcada como disponível novamente.

Após isso, a função dispara um signal que acorda todas as *threads* que estavam esperando por um sinal para acessar a posição (x,y). Por fim, a função libera o *lock* da posição (x,y) e termina.

2.3.3. move

Função executada por cada *thread* quando é criada. Ela recebe como parâmetro um ponteiro para um tipo estruturado thread_t, que armazena as informações da *thread* que foram lidas na entrada.

Inicialmente, a *thread* entra na primeira posição do seu caminho (que sempre estará livre já que por definição toda *thread* começa em uma posição diferente) e executa passa_tempo nessa posição. Em seguida, para todas as posições restantes no caminho, a *thread* tenta entrar na próxima posição com a função enter. Quando o acesso a essa posição for concedido, a *thread* sai da posição antiga com a função leave e executa a função passa_tempo na nova posição.

Essa sequência é repetida até que a *thread* passe por todas as posições no caminho. Quando isso acontecer, ela deixa a última posição que acessou e a função desaloca o ponteiro com as informações lidas na entrada.

2.3.4. passa_tempo

Função definida e disponibilizada na especificação do problema para simular uma tarefa de computação intensiva. Ela também realiza as impressões no terminal para que o fluxo do programa e de movimentação das *threads* sejam avaliados.

3. Sincronização entre as threads

Assim como foi citado anteriormente, as matrizes de *mutexes* e variáveis de condição juntamente das funções enter e leave são as estruturas responsáveis por realizar a sincronização das *threads*.

O controle do acesso a cada posição do status atual do *grid*, contido no tensor occupied, é realizado pelo *mutex* associado a essa posição, por isso essa estrutura foi modelada como uma matriz. Isso possibilita um controle de acesso a nível de célula, o que permite que as *threads* executem de forma independente, caso não estejam disputando pelo acesso a uma mesma posição.

Da mesma forma, as variáveis de condição também foram modeladas em uma matriz para que as *threads* possam entrar em espera e serem acordadas de acordo com a posição que desejam acessar. Essa situação faz com que o *lock* de uma posição apenas seja liberado temporariamente, o que assegura que o programa possa continuar executando sem estados de impedimento nos lugares do *grid* onde há disputa por posição e permite que *threads* que não estão na mesma região do *grid* executem de forma independente.

Assim, essa modelagem impede que *threads* entrem em espera sem necessidade e que *threads* acordem sem que haja alguma mudança no status da posição para a qual elas desejam se mover.

Com a modelagem dessas estruturas seguindo essa ideia, as funções enter e leave deverão apenas controlar as mudanças feitas no tensor occupied para atualizar a posição das *threads*. A função enter, primeiramente, adquire a trava da posição e verifica as condições para que a *thread* possa ser inserida em uma vaga dela, acessando o tensor occupied. Essa verificação é feita em um while e não em um if-else porque, uma vez que uma *thread* entrou em espera com o sinal wait, é possível que após ser acordada por um signal na posição que ela está esperando, outra *thread* tenha sido escalonada primeiro e as duas vagas estejam ocupadas ou que a *thread* que ainda permanece executando seja do mesmo grupo que a *thread* atual. Assim, o uso do while nesse caso garante que as condições de acesso sejam checadas novamente após a *thread* ser acordada, assegurando que as restrições do problema não sejam violadas em nenhum momento.

Quando a *thread* entra em espera, o *lock* da posição é liberado temporariamente. Isso permite que as outras *threads* continuem executando utilizando o *lock* daquela posição, fazendo com que não seja possível atingir um estado onde uma *thread* contém a trava da posição mas não consegue progredir e outra *thread* quer a trava para deixar a posição e liberar uma vaga mas não pode porque a trava está de posse da *thread* bloqueada.

Uma vez que o fluxo de execução saia do *loop*, a posse do *lock* na posição volta para a *thread* e sabemos que existem condições para que ela se mova para a posição que deseja. Assim, o tensor occupied é atualizado com a inserção da *thread* em uma das posições vagas e a trava da posição é liberada.

Após conseguir se mover para a posição atual, a *thread* deve deixar a posição que estava anteriormente. Para tanto, a função leave é chamada. Inicialmente, ela trava o acesso a posição que vai ser liberada usando o *mutex* dessa posição. Após isso, a função procura em qual das vagas a *thread* está armazenada, define a vaga como disponível e preenche com o valor -1 o id e o grupo da *thread*.

Em seguida, a função dispara um signal associado a variável de condição da posição liberada. Esse sinal irá acordar todas as *threads* que estão em espera pelo acesso à essa posição. Fazendo isso, as *threads* recém-acordadas passarão pelo teste de condição do *loop* novamente e, de acordo com as condições no momento em que cada uma for escalonada, poderão prosseguir com sua execução ou irão entrar em espera novamente. Por fim, a função leave libera a trava da posição e termina sua execução.

Essa estratégia implementada garante o acesso consistente à seção crítica e implementa a sincronização de forma adequada entre as *threads*, utilizando as variáveis de condição para controlar o estado das *threads* e liberar o *lock* de uma posição temporariamente. Isso impede que hajam estados que bloqueiem a execução de alguma *thread* por causa de espera com posse do *lock* e assegura o desempenho adequado para o programa, garantindo que as *threads* não entrem em espera sem necessidade e também não sejam acordadas quando alguma mudança que não as interessa acontece.

4. Conclusão

Com o desenvolvimento do programa, foi possível compreender melhor como o desenvolvimento com múltiplas *threads* é feito. Em especial, foi possível observar na prática as diferenças com relação ao desenvolvimento sequencial e como *multithreading* é capaz de proporcionar maior responsividade e desempenho aos programas.

Além disso, foi possível observar o impacto que as diferentes formas de se modelar o acesso exclusivo às estruturas compartilhadas causam no programa. Mais que isso, a modelagem proposta se beneficiou da característica dos acessos que o programa deveria realizar para propor uma estrutura de *mutexes* e variáveis de condição que permitissem que o controle de acesso fosse feito a nível de posição no *grid*.

Isso deu mais independência para as *threads*, o que propiciou um desempenho maior para o programa e um entendimento mais direto da dinâmica de controle de acesso às posições e de como as *threads* entram em espera e acordam a partir dos sinais.